

## المحاضرة الأولى مقدمة في تعلم الآلة

### 1. (ما هو تعلم الآلة؟) What Is Machine Learning

تعلم الآلة هو علم وفن برمجة الحواسيب بحيث تتمكن من التعلم من البيانات بدلاً من تلقي تعليمات صريحة. ويُعرّف أيضًا بأنه المجال الذي يمنح الحواسيب القدرة على التعلم الذاتي دون برمجة مباشرة، كما أوضحه آرثر صموئيل عام 1959. ومن منظور هندسي، يمكن القول إن البرنامج يتعلم عندما يتحسن أدائه في مهمة معينة (T)، وفق مقياس أداء محدد (P)، مع تراكم خبرة أو بيانات إضافية (E).

- البرمجة التقليدية: نضع القواعد + البيانات ← المخرجات.
- تعلم الآلة: نضع البيانات + المخرجات المتوقعة ← النموذج يتعلم القواعد بنفسه.




Figure 1-1. The traditional approach




Figure 1-2. The machine learning approach

مثال بسيط: البريد الإلكتروني: تصنيف Spam/Not Spam. بدلاً من كتابة قواعد معقدة (كلمات معينة، روابط مشبوهة)، النموذج يتعلم من آلاف الأمثلة.

### 2. (لماذا نستخدم تعلم الآلة؟) Why Use Machine Learning?

1. المشكلات التي تتطلب حلول تقليدية تحتاج إلى الكثير من التعديلات أو قوائم طويلة من الأوامر.

- في بعض التطبيقات نحتاج إلى كتابة آلاف القواعد البرمجية لمجرد التعامل مع حالات مختلفة.
- تعلم الآلة يمكن أن يتعلم هذه القواعد من البيانات مباشرة فيبسط الكود ويؤدي بشكل أفضل.
- مثال: مرشحات البريد الإلكتروني (Spam Filter). كتابة قواعد يدوية (كلمات مثل "جائزة"، "اربح الآن") غير فعالة، بينما نموذج ML يتعلم تلقائياً الكلمات والأنماط الأكثر دلالة على الرسائل المزعجة.

2. المشكلات المعقدة التي لا تعطي المناهج التقليدية فيها حلولاً جيدة

- بعض المشاكل معقدة للغاية بحيث لا يمكن صياغة خوارزمية دقيقة لها.
- تقنيات تعلم الآلة تستطيع إيجاد حلول تقريبية وفعالة.
- مثال: التعرف على الكلام (Speech Recognition) من المستحيل كتابة قواعد برمجية تميز بين جميع الأصوات البشرية، بينما أنظمة ML (مثل الشبكات العصبية العميقة) تتعلم التمييز من ملايين العينات الصوتية.

### 3. البيانات المتغيرة باستمرار (Fluctuating Environments)

- إذا كان العالم الذي يعمل فيه النظام يتغير بسرعة، فالقواعد الثابتة تصبح غير صالحة.
- تعلم الآلة تسمح بإعادة تدريب النماذج على بيانات جديدة بسهولة لتواكب التغييرات.
- مثال: أنظمة التوصية (Recommendation Systems) اهتمامات المستخدمين في Netflix أو YouTube تتغير يوميًا، والنماذج تعيد التدريب على بيانات جديدة باستمرار لمواكبة هذه التغيرات.

### 4. الحصول على رؤى ومعرفة من مشكلات معقدة أو بيانات ضخمة

- تعلم الآلة لا تستخدم فقط للتنبؤ، بل يساعدنا على اكتشاف أنماط جديدة غير مرئية.
- مثال: في المجال الطبي، تحليل بيانات آلاف المرضى قد يكشف علاقة جديدة بين نمط معين في صور الأشعة ومرض مبكر، ما يساعد الأطباء في التشخيص والبحث العلمي.

### 3. (أمثلة على التطبيقات) Examples of Applications

1. الرؤية الحاسوبية (Computer Vision): التعرف على الوجوه، السيارات الذاتية القيادة.
2. معالجة اللغة الطبيعية (NLP): الترجمة الآلية، تحليل المشاعر.
3. النظم الذكية: الروبوتات، المساعدات الشخصية.
4. الأعمال: اكتشاف الاحتيال البنكي، التسويق المستهدف.


### 4. (أنواع تعلم الآلة) Types of Machine Learning Systems

#### 4.1 Training Supervision (الإشراف على التدريب)

هذا التصنيف يعتمد على مقدار الإشراف (البيانات المصنفة) المتوفر أثناء التدريب:

#### • Supervised Learning (التعلم تحت إشراف):

- يستخدم بيانات تدريب تحتوي على المدخلات Inputs والمخرجات الصحيحة Labels.
- الهدف: تعلم علاقة أو دالة تربط المدخلات بالمخرجات.



○ أمثلة:

- التنبؤ بسعر منزل من خلال مساحة البيت وعدد الغرف. (Regression)
- تصنيف بريد إلكتروني إلى Spam أو Not Spam (Classification).



- **Unsupervised Learning (التعلم بدون إشراف):**

- البيانات غير مصنفة، الهدف هو اكتشاف بنى أو أنماط خفية.
- أمثلة:

- **Clustering:** تقسيم العملاء في مجموعة تسويق إلى شرائح حسب السلوك.




Figure 1-7. An unlabeled training set for unsupervised learning




Figure 1-8. Clustering

- **Dimensionality Reduction:** PCA. /


Anomaly Detection + Customer Segmentation

- **Semi-Supervised Learning (التعلم شبه تحت إشراف):**

- مزيج من بيانات قليلة مصنفة وكمية كبيرة غير مصنفة.
- غالبًا ما يستخدم في مجالات يصعب فيها وسم البيانات يدويًا.
- مثال: صور Google Photos ، يتم وسم صور قليلة يدويًا ثم يستخدم النموذج الصور غير المصنفة لتحسين الأداء.

- **Reinforcement Learning (التعلم بالتعزيز):**

- وكيل (Agent) يتفاعل مع بيئة (Environment) ، ويتعلم من خلال التجربة والخطأ.
- يحصل على مكافآت (Rewards) أو عقوبات (Penalties) بناءً على أفعاله



○ أمثلة:

## 5- Self- Supervised Learning

- تدريب برنامج يلعب الشطرنج. (AlphaGo)
- روبوت يتعلم المشي أو الإمساك بالأشياء.

## 4.2 Batch vs Online Learning (التعلم الدفعي مقابل التعلم المتدرج)

هذا التصنيف يعتمد على كيفية تدريب النموذج:

## • Batch Learning (التعلم الدفعي):

النموذج يتعلم مرة واحدة باستخدام كل البيانات دفعة واحدة. بطيء عند تحديث البيانات لأنه يتطلب إعادة التدريب من الصفر.  
أمثلة: أنظمة كشف الاحتيال البنكي التي تُحدث كل أسبوع.

## • Online Learning (التعلم المتدرج/المتتابع):

النموذج يتعلم تدريجيًا عند وصول بيانات جديدة. مناسب للتعامل مع البيانات المتدفقة. (Streaming Data)  
أمثلة: أنظمة التوصية مثل YouTube أو Netflix ، تتغير التوصيات عند كل نظرة جديدة.

## 4.3 Instance-Based vs Model-Based Learning

هذا التصنيف يعتمد على الطريقة التي يستخدمها النظام للتعميم من البيانات:

## • Instance-Based Learning (التعلم المعتمد على الأمثلة):

النموذج يخزن الأمثلة الجديدة، وعند التنبؤ يقارن المثال الجديد مع الأمثلة المخزنة باستخدام مقياس تشابه. أمثلة:

• K-Nearest Neighbors (KNN).

• أنظمة تعتمد على حساب المسافة بين النقاط. Costumer Segmentation

## • Model-Based Learning (التعلم المعتمد على النماذج):

النموذج يبني علاقة رياضية عامة بين المدخلات والمخرجات. أمثلة:

• Linear Regression.

• Neural Networks.

□ مقارنة:

• Instance-Based يشبه "الحفظ" والتكرار. (memorization)

• Model-Based يشبه "الفهم" وبناء قاعدة عامة للتنبؤ.

## ◆ ملخص الفقرة

- تصنيف حسب الإشراف. Supervised, Unsupervised, Semi-Supervised, Reinforcement.
- training : تصنيف حسب التدريب. Batch vs Online
- generalization strategy : تصنيف حسب استراتيجية التعميم. Instance-Based vs Model-Based

## 5 .Main Challenges of Machine Learning (تحديات تعلم الآلة)

1. Insufficient Data (قلة البيانات): النماذج تحتاج بيانات كثيرة لتعمل جيدًا. مثال: التعرف على الصور يتطلب آلاف الأمثلة.

2. Nonrepresentative Data (عدم تمثيل البيانات): إذا لم تكن العينة ممثلة للواقع → النموذج يفشل.
3. Poor-Quality Data (جودة البيانات ضعيفة): بيانات ناقصة، ضوضاء، أخطاء.
4. Irrelevant Features (خصائص غير مفيدة): اختيار الخصائص (Feature Selection) مهم جدًا. feature engineering
5. Overfitting (زيادة التخصيص): النموذج يتعلم الضوضاء بدلاً من النمط العام. مثال: حفظ الأسئلة بدلاً من فهم المادة.
6. Underfitting (قلة التخصيص): النموذج أبسط من اللازم → لا يلتقط الأنماط.
7. Stepping Back (العودة خطوة للخلف): إعادة صياغة المشكلة بطريقة أفضل إذا لم ينجح النموذج. feedforward propagation

مثال يوضح الفرق بين البرمجة التقليدية وتعلم الآلة.

"برنامج تقليدي بسيط لنصف الرقم هل هو "زوجي" أم "فردى"

```
def traditional_program(n):
```

```
    if n % 2 == 0:
```

```
        return "زوجي"
```

```
    else:
```

```
        return "فردى"
```

# تجربة

```
for x in [3, 8, 11]:
```

```
    print(x, ">", traditional_program(x))
```

"برنامج بسيط يستعمل تعلم الآلة لتعلم الفرق بين "زوجي" و "فردى"

```
from sklearn.linear_model import LogisticRegression
```

# بيانات تدريب: الأرقام والوسوم

```
x = [[0],[1],[2],[3],[4],[5],[6],[7]] # المدخلات
```

```
y = [0,1,0,1,0,1,0,1] # زوجي=1، فردى=0
```

# تدريب النموذج

```
model = LogisticRegression()
```

```
model.fit(X, y)
```

# تجربة على أرقام جديدة

```
test_numbers = [[8],[9],[15],[22]]
```

```
pred = model.predict(test_numbers)
```

```
for num, label in zip(test_numbers, pred):
```

```
    print(num[0], ">", "زوجي" if label==1 else "فردى")
```